Klasifikácia environmental sounds pomocou neurónových sietí

Cieľ projektu

Cieľom projektu je porovnať dva typy neural networks — CNN a LSTM — v úlohe klasifikácie environmental sounds. Každá architektúra bude trénovaná na dvoch rôznych audio reprezentáciách: log-mel-spectrogramoch a MFCC. Výsledkom budú štyri experimenty, ktorých results budú vzájomne porovnané z hľadiska accuracy, stability trainingu a výpočtovej náročnosti.

Dataset

Projekt využíva dataset ESC-50, ktorý obsahuje 2000 audio nahrávok rovnomerne rozdelených do 50 tried (40 samples na triedu). Každý clip trvá 5 sekúnd, je v mono WAV formáte so sample rate 44,1 kHz. Dataset je vopred rozdelený do 5 foldov pre cross-validation.

Audio reprezentácie

Log-mel-spectrogram — časovo-frekvenčná reprezentácia signálu, kde frekvenčná os je transformovaná na mel scale a amplitúdy sú prevedené do logaritmickej škály. Lepšie zodpovedá ľudskému vnímaniu zvuku a zvýrazňuje rozdiely v tichších častiach signálu.

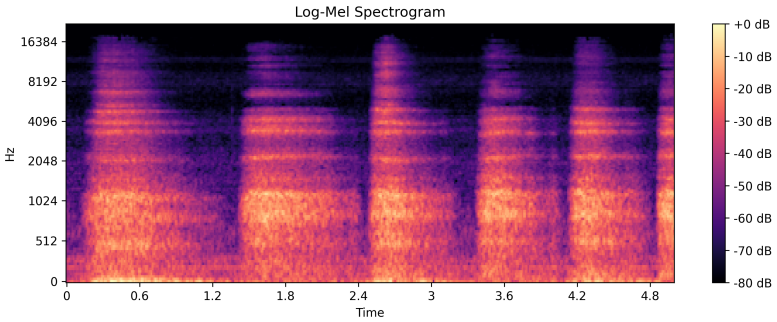

Obr. 1: Ukážka log-mel-spectrogramu z ESC-50 datasetu (source: 1-30709-B-23.wav).

MFCC (Mel-Frequency Cepstral Coefficients) — kompaktná reprezentácia odvodzovaná z log-mel-spectrogramu pomocou discrete cosine transform. Zachytáva tvar spectral envelope signálu.

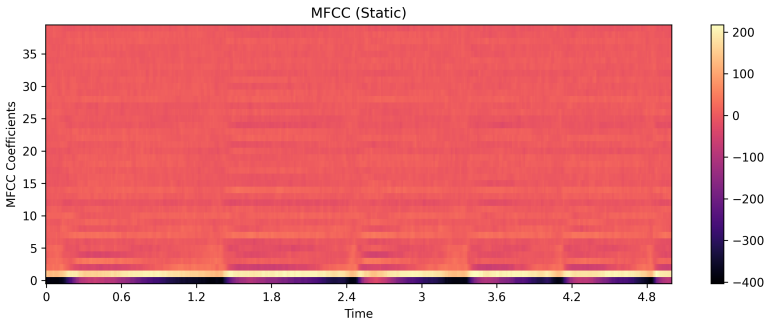

Obr. 2: Ukážka MFCC features z ESC-50 datasetu (source: 1-30709-B-23.wav).

Architektúry

CNN (Convolutional Neural Network) — spracováva vstupnú reprezentáciu ako 2D input. Convolutional filters detekujú lokálne patterns v spectrograme, postupné layers extrahujú čoraz abstraktnejšie features. Output convolutional layers je spracovaný fully connected network pre classification.

LSTM (Long Short-Term Memory) — recurrent network spracovávajúca input ako sequence časových krokov. Udržiava vnútorný cell state, ktorý umožňuje zachytávať long-term dependencies v signáli. Tri gates (forget, input, output) riadia flow informácií.

Experimenty

Experiment	Architektúra	Reprezentácia
1	CNN	Log-mel-spectrogram
2	CNN	MFCC
3	LSTM	Log-mel-spectrogram
4	LSTM	MFCC

Rozdelenie úloh

Člen tímu	Zodpovednosť
Osoba 1	Data infrastructure — loading, feature extraction, dataset class, config, logging
Osoba 2	CNN — model, training loop, config. Training a tuning na oboch reprezentáciách.
Osoba 3	LSTM — model, training loop, config. Training a tuning na oboch reprezentáciách.
Osoba 4	Evaluation — training curves, confusion matrices, accuracy porovnanie. Report a prezentácia.

Rozdelenie nie je striktné — členovia tímu si vzájomne pomáhajú podľa potreby.

Postup práce

1. Príprava data infrastructure — loading ESC-50, extrakcia log-mel-spectrogramov a MFCC, implementácia dataset class a config systému.
2. Training modelov — CNN a LSTM na oboch reprezentáciách (4 experimenty).
3. Hyperparameter tuning a optimalizácia.
4. Evaluation a porovnanie results.
5. Záverečná správa a prezentácia.